DGX Spark TP=2 架構升級全量對比與 2M 緩存池實測報告

4 槽基線 vs P6/P8 NVMe 冷池 vs P10 2M 共享緩存池與 1 小時多輪讀圖高壓長跑實測

報告日期：2026-11-08
硬體集群：2× DGX Spark (GB10 128GB UMA)
互聯拓撲：ConnectX-7 200G RoCEv2 (185 Gbps)
最新標籤：`v2b2-p10-1hour-vision-principal-verified`

一、執行摘要與核心突破總覽

本報告完整記錄雙節點 NVIDIA DGX Spark（`spark-9e5c` + `spark-7579`）運行 **DeepSeek-V4.1-Flash-1017-TF（Plus-Ten 2.9bpw + 6-bit Head/MTP + 官方 43 層 FP32 偏置）** 在 **Stage 2B-2 P10（2M 共享 KV 快取池解耦升級）** 與先前歷史階段之全量 A/B 實測對比，以及剛完賽的 **連續 1 小時（3,646 秒）高壓隨機混流馬拉松（含 140 筆多輪讀圖測試）** 完整評測數據。

共享 KV 緩存池擴展	1 小時馬拉松 200 OK 交付	多輪讀圖 TURN 2 加速	高壓長跑後可用顯存
2,097,152 toks	**100.0%** (783/783)	**-20.1%** TTFT	**3.7 GiB** (Node 1)
翻倍 (+100%) · 解耦單請求 1M 視窗	0 錯誤 · 0 秒退 (429) · 0 OOM 崩潰	Turn 1 4.10s → Turn 2 3.28s (140/140 通過)	穩守 3.5G 水位線 · Node 2 剩 6.1G

P10 2M 共享緩存池與 1 小時多輪讀圖四大關鍵實證：

1. **單請求 Context 與共享 Pool 成功解耦（Patch 0063）：** 原生引擎先前將 `--context` 與 `.pool` 硬綁定，導致直接給 `--context 2097152` 被 `error.PastNative` 攔截。本次透過補齊 `native.zig` 的 `TF_DS_WINDOW` 環境變數解析，使單請求上下文維持在 1,048,576 tokens，而 8 個併發 Stream 共享的實體 KV 池翻倍至 **2,097,152 tokens**。
2. **2M 專屬 RoPE 表格離線生成與雙機同步：** 透過容器調用 `ops.rope_cs` 在 CPU 耗時 11.4 秒生成 2,162,688 rows 的 4 份二進位表（每份 264 MB），前 1.11M rows 與官方 1M 表格位元級 100% 一致，透過 200G RoCE 同步至 `/home/joseyarashio/dsv41-2m-kit`。
3. **1 小時全維度馬拉松 100% 成功交付（783/783 筆）：** 連續 60.8 分鐘 8 槽位高壓混流（C8）完成 783 筆任務，達成 **100% 200 OK 成功率**（429 秒退 0 筆、500 異常 0 筆），累計產出 24.8 萬 tokens、命中 **5,640,192 個快取 tokens**。
4. **多輪讀圖高壓長測驗證零洩漏：** 隨機注入 140 筆多輪圖像問答（佔比 17.9%），Turn 1 圖片編碼 TTFT 平均 4.107 秒，Turn 2 圖片快取復用（Vision Tower Skip）TTFT 平均降至 **3.280 秒（加速 20.1%）**，證實 Scratch Arena 在連續高壓讀圖下完全無顯存洩漏。

二、更動架構前後：系統與引擎核心配置全對照

架構維度 / 子系統	初始未修補基線 (`v0-baseline-1012`)	更動架構前：4 槽標準基線 (`v2b2-p4h-strata-baseline`)	更動架構後：P8 NVMe 冷池 (`v2b2-p8-nvme-cold-pool`)	最新 P10：2M 共享池 + C8 槽位 (`v2b2-p10-1hour-vision-verified`)
GPU 活躍併發槽位	4 槽 (`--parallel 4`)	4 槽 (`--parallel 4`)	6 槽 (`--parallel 6`)	**8 槽 (`--parallel 8`, `TF_DS_STREAMS=8`)**
實體 KV Cache 緩衝池容量	1,048,576 tokens (1M)	1,048,576 tokens (1M)	1,048,576 tokens (1M)	**2,097,152 tokens (2M, `TF_DS_WINDOW`)**
單一請求 Context 視窗	1,048,576 tokens (1M)	1,048,576 tokens (1M)	1,048,576 tokens (1M)	**1,048,576 tokens (1M, 硬邊界對齊)**
RoPE 旋轉位置編碼表格	1,114,112 rows (544 MB)	1,114,112 rows (544 MB)	1,114,112 rows (544 MB)	**2,162,688 rows (1,056 MB, 專屬二進位)**
算子解碼窗口與核心庫	48-row (198 cubins)	48-row (198 cubins)	64-row (214 cubins, v0.7.5 S5)	**64-row (214 cubins, 支援 32-stream)**
思維鏈過濾與防自我模仿	未啟用 (易死循環)	未啟用	`--drop-reasoning-history --keep 2`	**`--drop-reasoning-history --keep 2`**
多輪看圖暫存管理	原生靜態分配 (~0.71G)	原生靜態分配	PR #112 Scratch Arena (0.23G)	**Scratch Arena + Vision Tower Skip**
前綴快取協同與網關	無前綴協同	Strata Single-Flight 初版	Single-Flight 狀態機 + 10s Aging	**Single-Flight + 15s 硬反飢餓 + TTFE**
多級快取層次結構	RAM 熱池 2.0 GiB	RAM 熱池 3.0 GiB	3.0G RAM + 32G NVMe Imprint	**2M Pool (RAM) + 32G NVMe Imprint**

二、全維度標準客觀題庫與單流 / 併發性能對照

30 題標準五維度、單流極限速度、預填插隊延遲與 C1~C6 併發擴展數據

評測腳本：`benchmarks/run_full_eval.py`
測試環境：雙機 Port 8889 實機端到端實測

一、30 題五維度標準題庫評測對比（品質零退步）

評測維度 / 題型	Step 1 基線 (v1-step1-zig)	Stage 2B-2 P1 (v2b2-p1-verified)	Stage 2B-2 P7 (v2b2-p7-e2)	Stage 2B-2 P10 (2M Pool) (v2b2-p10-2m-shared-pool)	品質判定與實測細節
題庫總答對率 (30 題)	28 / 30 (93.3%)	28 / 30 (93.3%)	**28 / 30 (93.3%)**	**28 / 30 (93.3%)**	**歷經 5 代配方升級，客觀能力 100% 守住最高線**
數學推理 (GSM8K/Comb 5題)	4 / 5	4 / 5	4 / 5	**4 / 5**	**組合計數、機率、代數全部秒回 (102~123 tok/s)**
MMLU-Pro 專業知識 (10題)	9 / 10	9 / 10	9 / 10	**9 / 10**	**涵蓋計算機架構、化學、物理、熱力、線性代數**
Python 程式碼 (Assert 5題)	5 / 5 (100%)	5 / 5 (100%)	5 / 5 (100%)	**5 / 5 (100%)**	**Dijkstra、區間合併、Edit Distance 全通過直譯**
IFEval 嚴格指令約束 (5題)	5 / 5 (100%)	5 / 5 (100%)	5 / 5 (100%)	**5 / 5 (100%)**	**純 JSON、禁用指定字母、精確項目計數全部守住**
Agent 工具調用與看圖 (5題)	5 / 5 (100%)	5 / 5 (100%)	5 / 5 (100%)	**5 / 5 (100%)**	**含 11K tokens 圖像四象限問答與快取命中 (TTFT 0.74s)**
合成視覺探針 (vision_probe.py)	未支援	4 / 4 PASS	4 / 4 PASS	**4 / 4 PASS**	**紅圓/綠方幾何、象限計數、OCR INVOICE-8899 滿分**

二、單流解碼速度、冷預填吞吐與增量插隊延遲對照

性能維度 / 負載條件	Step 1 基線	Stage 2B-2 P1	Stage 2B-2 P7	Stage 2B-2 P10 (2M Pool)	增益幅度與實測備註
單流極限代碼 (temp=0.00)	88.30 tok/s	95.52 tok/s	93.29 tok/s	**92.28 tok/s**	**MTP 接受率 80.3% · 每輪 3.76 tokens**
日常代碼生成 (temp=0.30)	74.00 tok/s	90.20 tok/s	80.06 tok/s	**79.00 tok/s**	**MTP 接受率 74.1% · 每輪 3.07 tokens**
結構化 JSON 輸出 (temp=0.00)	94.20 tok/s	103.80 tok/s	106.86 tok/s	**105.54 tok/s**	**MTP 接受率 87.4% · 每輪 4.86 tokens**
冷預填吞吐 (8K tokens)	1,890 tok/s	2,243 tok/s	2,192 tok/s	**2,231 tok/s**	**Cortex-X925 超大核綁定維持極速 (2.56s)**
冷預填吞吐 (32K tokens)	1,620 tok/s	2,020 tok/s	2,070 tok/s	**2,030 tok/s**	**61,308 tokens 冷預填耗時 30.19 秒**
長預填期間短問插隊 (Cut-In TTFT)	31.70 秒	1.52 秒	1.02 秒	**1.16 秒**	**TF_FILL_CUT_IN=8192 生效，短請求秒進**

三、併發擴展聚合吞吐對照（Port 8889 實機量測）

併發層級 (Concurrency)	Step 1 基線	4 槽基準 (P4)	6 槽基準 (P7)	8 槽 2M 池 (P10)	吞吐增長趨勢與實測表現
C1 獨占吞吐	75.60 tok/s	82.10 tok/s	77.14 tok/s	**76.30 tok/s**	單流受限於顯存頻寬與通訊往返
C2 併發吞吐	86.00 tok/s	90.20 tok/s	88.91 tok/s	**88.43 tok/s**	+15.9% 擴展，多流計算掩蓋通信延遲
C4 併發吞吐	112.20 tok/s	116.31 tok/s	114.14 tok/s	**113.20 tok/s**	+48.3% 擴展，4 槽位穩定飽和
C6 併發吞吐	不支援 (4 槽)	不支援 (4 槽)	128.91 tok/s	**126.24 tok/s**	**+65.4% 擴展，64-row cubin 算子全開**
C14 突發壓力測試 (16路並發)	未測試	第 9 路秒退	16/16 正常	**16/16 全數 200 OK**	**8 活躍槽 + 隊列平穩消化，零崩潰**

三、1 小時多輪讀圖高壓混流馬拉松深度對比

P6 5 小時馬拉松 vs P10 1 小時馬拉松（含 140 筆多輪讀圖）全量對照

最新測試檔案：`omni_eval_1hour_vision_2m_pool.json`
總運行秒數：3,646.71 秒 (60.8 分鐘)

一、高壓馬拉松長跑關鍵指標全景對照

指標類別 / 關鍵參數	初期 30 分鐘壓測 (phase9c-baseline)	P6 5 小時馬拉松 (stress_5hour)	P10 1 小時馬拉松 (omni_eval_1hour_vision)	調優突破與實測結論
持續測試時長	1,800 秒 (30 分鐘)	18,046 秒 (5.01 小時)	**3,646 秒 (1.01 小時)**	嚴格依照標準長跑時長滿載執行
測試並發架構	6 槽位閉環 (C6)	8 槽位閉環 (C8)	**8 槽位 (C8) + 2M 共享池**	**2M 共享 KV 池提供更充裕並發空間**
總完成請求數	381 筆	3,519 筆	**783 筆**	每小時完成量維持在 780~800 筆之飽和上限
成功交付率 (HTTP 200 OK)	99.21% (378 筆)	95.31% (3,354 筆)	**100.0% (783 筆)**	**全場 100% 成功交付，零丟失**
429 降級秒退次數 / 比例	3 筆 (0.79%)	165 筆 (4.69%)	**0 筆 (0.0%)**	**零 429 秒退，隊列排程與槽位完全自洽**
500 異常 / OOM 崩潰 / 死鎖	0 筆 (0.0%)	0 筆 (0.0%)	**0 筆 (0.0%)**	**零錯誤保持記錄，底層穩定性堅如磐石**
多輪讀圖任務 (Vision Tasks)	0 筆 (未注入)	0 筆 (未注入)	**140 筆 (17.9% 流量)**	**首度成功將多輪圖像問答混入高壓長跑**
多輪讀圖成功率	N/A	N/A	**140 / 140 (100.0%)**	**包含 Turn 1 載入與 Turn 2 上下文復用**
讀圖 Turn 1 首字延遲 (TTFT)	N/A	N/A	**平均 4.107 秒**	圖片上傳、預處理與 Vision Tower 編碼
讀圖 Turn 2 快取復用延遲 (TTFT)	N/A	N/A	**平均 3.280 秒**	**加速 20.1% (最快 0.565 秒秒回)**
累計命中 Prompt Cache Tokens	1,820,416	30,920,704	**5,640,192 (5.64M)**	**平均每筆請求命中 7,203 快取 tokens**
累計生成 Tokens 數量	146,720	1,465,210	**248,621 (24.8萬)**	穩定輸出高密度代碼與結構化推理

二、多輪讀圖（Multi-Turn Vision）在 2M 緩存池下的架構行為審計

多輪讀圖長測實測機理與亮點：
1. **Vision Tower Skip 零重複計算：**在 Turn 1 階段，模型需呼叫 Vision Tower 將 256x256 圖像解析為視覺嵌入 tokens（單次約需 0.5~1.0 秒）；在 Turn 2 中，因前序圖像與提問已存在於 2M 共享池中，直接命中快取跳過 Vision Tower 計算，平均首字延遲自 4.107 秒驟降至 3.280 秒（最快達 0.565 秒）。
2. **Scratch Arena 顯存安全回收：**先前未修補版本在多輪看圖時，每張圖片會殘留約 0.48 GiB 的中間暫存；本次實測 140 輪連續讀圖，Scratch Arena 在每個請求結束後精準歸還顯存，Node 1 實體顯存全程未出現爬坡累積現象。

四、實體顯存帳本、外部審查結論與 Phase 11 調優路線圖

雙節點顯存下限水位、Opus 5.5 + Astra 6 批判結論與嚴格「逐項推進」計畫

審查模型：Claude Opus 5.5 + GPT-6 Astra
生產依據：「逐項推進、不進則退」原則

一、雙節點實體顯存／記憶體成分帳本（最重壓力長跑後）

記憶體成分項目	P6 5小時長跑後 (1M 池基準)	P10 1小時長跑後 (2M 共享池基準)	顯存佔比與安全屬性	架構意義與邊界分析
模型靜態權重工作集	99.2 GiB	**99.2 GiB**	82.0%（常駐）	Plus-Ten 2.9bpw 骨幹 + 43層 FP32 偏置
實體 KV Cache 緩衝池	6.44 GiB（1M 池）	**7.78 GiB（2M 池）**	6.4%（靜態鎖定）	**MLA 壓縮 890 B/token，淨增僅 1.34 GiB**
RoPE 旋轉編碼表 (DeviceBuffer)	0.53 GiB	**1.00 GiB**	0.8%（靜態鎖定）	由 1.11M rows 擴增至 2.16M rows 表格
主機 Prompt Cache 快照池	3.0 GiB	**3.0 GiB**	2.5%（上限鎖定）	存放不可變 chunk-end 快照，消除重複預填
CUDA Graph 靜態記憶體	0.65 GiB (128 graphs)	**0.65 GiB (128 graphs)**	0.5%（靜態鎖定）	PR #119 隔離保護，零 capture cascade
Node 1 (spark-9e5c) 實體可用 RAM	3,952 MiB (3.86 GiB)	**3,788 MiB (3.70 GiB)**	**3.1%（動態餘裕）**	**穩守 High-Watermark (3.5 GiB) 警戒線之上**
Node 2 (spark-7579) 實體可用 RAM	5,921 MiB (5.78 GiB)	**6,246 MiB (6.10 GiB)**	**5.0%（動態餘裕）**	**Worker 節點餘裕充裕，Swap 維持 0 MB**

二、外部雙代理（Claude Opus 5.5 + GPT-6 Astra）批判審查結論

外部專家評審共識：

1. **[對 2M 緩存池定調：正向且達標]：** 2M 共享池成功透過 TF_DS_WINDOW 解耦單請求 context，在 8 槽位高壓長跑下達成了 100% 200 OK，且 140 筆多輪讀圖全數通過。MLA 的 890 B/token 壓縮架構將 2M 實體顯存代價精確控制在 +1.34 GiB，是目前 DGX Spark UMA 記憶體下的最佳甜蜜點。
2. **[Node 1 顯存餘量 3.7 GiB 之邊界警示]：** 審查指出 3.7 GiB 距離 3.5 GiB High-Watermark 僅剩約 200 MiB 裕度。若遭遇極端突發（例如多路同時發送 4K+ 超高解析度圖片或 4K+ 長輸出），Linux 內核可能短暫觸發 Swap 換頁。建議維持當前 2M 上限，**絕對禁止盲目推進至上游激進的 7.34M KV 池**。
3. **[讀圖 Turn 2 加速瓶頸揭秘]：** Turn 2 TTFT（3.28s）雖比 Turn 1（4.10s）加速 20.1%，但未如純文本般達到亞秒級（0.5s），主因是當前在 8 併發滿載下，多個請求正在同時爭搶 GPU 解碼輪次與隊列排程；在單流獨占測試下，讀圖快取命中實測 TTFT 實為 0.74 秒。

三、Phase 11 逐項推進調優路線圖（嚴格「逐項推進、不進則退」）

階段代號	調優目標與具體內容	預期效益	全量回歸檢驗閘門 (Pass / Fail Criteria)	回退機制
Phase 11A	**合入 MiaAI-Lab Patch 0048 (DSML 工具調用即時串流)** 在 `tool_stream.zig` 實裝 DSML 狀態機，使工具名稱與參數隨 token 解碼即時送出	徹底消除 Agent 長參數等待 1~4 秒無事件之停頓感，大幅提升 OpenCodex / Hermes 體感流暢度	**閘門：**30 題標準題庫 Agent 5/5 項通過；OpenCodex 工具調用 TTFT 保持 ≤ 0.5s；首字不得洩漏內部標記	若工具解析語法錯誤或無法串流，立即回退至現有 `tool_parse.zig` 整句解析
Phase 11B	**讀圖優先權隊列微調 (Vision Fast-Path)** 在 Port 8889 Proxy 針對多輪讀圖之 Turn 2 請求賦予暫時性高優先提拔，縮減滿載時的排隊等待	將高壓混流下的多輪讀圖 Turn 2 TTFT 由 3.28 秒進一步壓低至 1.5 秒以內	**閘門：**Turn 2 TTFT 改善 ≥ 30%；且不得引起普通文本 P0 請求之延遲反轉（P0 TTFT ≤ 2.0s）	若文本任務出現飢餓延遲，立即復原隊列調度權重
Phase 11C	**動態高水位主動預警 (Adaptive Memory Cushion)** 當 Node 1 可用 RAM 短暫跌破 3.6 GiB 時，自動限制第 8 槽位進入，保留 2 槽作為突發圖文安全緩衝	根絕極端高壓下的 Swap 抖動與 OOM 風險，將可用顯存硬防線拉升至 4.0 GiB+	**閘門：**C14 突發與多圖併發壓測下，Node 1 可用顯存全程 ≥ 3.8 GiB，且總吞吐不降低 > 5%	若動態限制導致吞吐大幅下降，回退至靜態 8 槽位設定

報告檔案路徑：`/home/joseyarashio/dgx-spark-tp2-recipes/reports/DGX_Spark_TP2_2M_Pool_Comprehensive_Benchmark_Report_20261108.pdf`
可重現驗證與原始數據：`/home/joseyarashio/dgx-spark-tp2-recipes/benchmarks/results/` • GitHub: `https://github.com/joseyarashio/dgx-spark-tp2-recipes` (Tag: `v2b2-p10-1hour-vision-principal-verified`, Commit: `a46e1a4`)