DGX Spark TP=2 架構升級全量對比與 5 小時馬拉松報告

更動架構前 4 槽基線 vs Strata Single-Flight vs P5 6槽8佇列擴展 vs P6 NVMe 分層快取與 5 小時長跑實測

報告日期：2026-11-07
硬體集群：2× DGX Spark (GB10 128GB UMA)
互聯拓撲：ConnectX-7 200G RoCEv2 (185 Gbps)
版本標籤：`v2b2-p7-e2-aging-cache-aware`

一、執行摘要與核心突破總覽

本報告完整記錄雙節點 NVIDIA DGX Spark（`spark-9e5c` + `spark-7579`）運行 **DeepSeek-V4.1-Flash-1017-TF（Plus-Ten 2.9bpw + 6-bit Head/MTP + 官方 43 層 FP32 路由偏置）** 在**架構更動前（4 槽基線）**與**新架構（Strata Single-Flight 前綴快取協同 + 2048 粒度快取 + 8K 增量插隊窗口 + 3.0 GiB 主機快取池 + P5 6槽8佇列擴展 + P6 High-Watermark NVMe 分層快取）**之全量 A/B 實測對比，以及連續 5 小時（3,519 筆請求）高壓隨機馬拉松完賽統計。

C6 六槽滿載聚合吞吐	Part D 混合負載 / 錯開進場	5 小時馬拉松 200 OK 交付率	8K 插隊 / D3 多輪快取 TTFT
170.07 tok/s	**5.87s / 12.82s**	**95.31%** (3,354筆)	**1.13s / 0.53s**
+51.0% 突破 (4槽基線 112.66 tok/s)	加速 5.8 倍 (基線 33.90s / 21.78s)	較初版 65.0% 飆升 +30.31% • 79.1% MTP	插隊快 30.5% • Turn 6 快 3.0 倍

架構升級四大關鍵實證結論：

1. **併發吞吐天花板突破 (+51.0%)：**配合 64-Row cubin 算子（214 個 AOT 核心）將雙機並行槽位由 4 擴展至 6（`--parallel 6`）與 8 佇列緩衝（總承載 14 路），聚合吞吐由 **112.66 tok/s 躍升至 170.07 tok/s**，且 30 題五維度客觀題庫維持 **28/30 (93.3%)** 零退步。
2. **徹底消滅多代理 Delay-Hit 雪崩：**Port 8889 Proxy 實裝 **Strata Single-Flight 首 Chunk 即時廣播 + 60s 確定態前綴視窗**，D2 錯開進場 4 個 Worker 的 TTFT 由 `14.48s ~ 7.78s` 全面壓平至 **`0.95s ~ 0.96s`**；D4 混合負載總耗時由 **33.90 秒暴跌至 5.87 秒（快 5.8 倍）**。
3. **2048 粒度快取與 8K 增量插隊：**將引擎 `Store.init min_prompt` 由 4096 放寬至 **2048 tokens**，D3 工具鏈第 6 輪（2,669 tokens）精確命中 2,048 快取 tokens，TTFT 自 1.594s 降至 **0.529s（快 3.0 倍）**；`TF_FILL_CUT_IN=8192` 使 32K 冷預填期間短請求插隊延遲降至 **1.13 秒**。
4. **5 小時高壓馬拉松驗證零洩漏：**300 分鐘連續 8 併發壓測完成 **3,519 筆請求（處理 5,602 萬 Prompt Tokens、產出 146.5 萬 Tokens）**，200 OK 交付率達 **95.31%**，MTP 接受率全程維持 **79.11%**，完賽後雙機可用記憶體穩守 **3.86 GiB / 5.78 GiB**（零 OOM、零 RDMA 斷線）。

二、更動架構前後：系統與引擎核心配置全對照

架構維度 / 子系統	初始未修補基線 (`v0-baseline-1012`)	更動架構前：4 槽標準基線 (`v2b2-p4h-strata-baseline`)	更動架構後：P5 + P6 最終生產架構 (`v2b2-p6-5hour-marathon-verified`)
GPU 活躍併發槽位	4 槽 (`--parallel 4`)	4 槽 (`--parallel 4, max_batch=4`)	**6 槽 (`--parallel 6, max_batch=6`)**
Port 8889 待命佇列容量	4 佇列 (串流提前釋放失效)	4 佇列緩衝 (總在線承載 8 路)	**8 佇列緩衝 (總在線承載 14 路，第 15 路 1.2ms 秒退)**
階梯式超時看門狗 (Tiered 429)	`[20, 15, 10, 5]` 秒	4 階梯：`[20.0, 15.0, 10.0, 5.0]` 秒	**8 階梯 (25s 起每階退 3s)：`[25, 22, 19, 16, 13, 10, 7, 4]` 秒**
多代理前綴快取協同 (Strata)	無 (各自獨立重複預填)	無 (發生 Delay-Hit 排隊與重複預填)	**Strata Single-Flight 首 Chunk 即時廣播 + 60s 確定態視窗**
Prompt Cache 起跑最小粒度	4,096 tokens	4,096 tokens (`min_prompt = 4096`)	**2,048 tokens (`min_prompt = 2048`，對齊 `chunk_rows`)**
長預填增量插隊窗口 (Cut-in)	無插隊 (需苦等 26.35s)	`TF_FILL_CUT_IN = 4096` (4K 增量窗口)	**`TF_FILL_CUT_IN = 8192` (8K 增量窗口，支援大工具結果插隊)**
主機快取記憶體池 (Prompt Cache)	預設 (無快照預算控管)	`--prompt-cache-gib 2.0` (2.0 GiB)	**`--prompt-cache-gib 3.0` (3.0 GiB 主機快取池 + 1.05M KV Pool)**
分層冷盤快取守衛 (Cold KV)	無	無	**LMCache 風格 High-Watermark (3.5 GiB) + 雙層 TTL (10m/24h, NVMe)**
AOT 算子與解碼列數上限	198 cubins / `max_rows=48`	214 cubins / `max_rows=64, streams=32`	**214 cubins (含 16 個 64-row 算子) / `max_rows=64` 滿載驅動 6 槽**
CPU 核心親和性與記憶體修補	全核混跑 (X925+A725 抖動)	10 顆 3.9GHz Cortex-X925 超大核綁定 PR #112 看圖 Arena + PR #115 原地擴展 + PR #116	**`--cpuset-cpus=5-9,15-19` 綁定 + PR #95/#112/#115/#116 全套硬化**

三、Part A & Part B：30 題五維度題庫、單流解碼、冷預填與插隊延遲對比

以下數據全數取自雙機實測原始 JSON 產物（`benchmarks/results/full_eval_*.json`），涵蓋從初始未修補基線、10/27 初始 2B-2 基線、更動架構前基線（P4h），到導入 Strata + 8K 插隊（P4n）、擴展 6 槽 8 佇列（P5）與加入 NVMe 分層快取（P6）的逐階段演進：

評測項目 / 性能指標	0. 原始基線 `v0-1012`	1. 初始 2B-2 `live-1027`	2. 架構更動前 P4h （4槽基線）	3. Strata+8K P4n （4槽協同）	4. 擴展 6槽8佇列 P5 （6槽擴展）	5. 最終生產架構 P6 （6槽+ColdKV）
Part A：30 題五維度題庫總分	—	28 / 30 (93.3%)	28 / 30 (93.3%)	28 / 30 (93.3%)	28 / 30 (93.3%)	**28 / 30 (93.3%)**
└數學推理 (5題) / MMLU-Pro (10題)	—	4/5 • 9/10	4/5 • 9/10	4/5 • 9/10	4/5 • 9/10	**4/5 (80%) • 9/10 (90%)**
└Python `assert` (5題) / IFEval (5題)	—	5/5 • 5/5	5/5 • 5/5	5/5 • 5/5	5/5 • 5/5	**5/5 (100%) • 5/5 (100%)**
└Agent 工具與多輪看圖 (5題)	—	5/5 (100%)	5/5 (100%)	5/5 (100%)	5/5 (100%)	**5/5 (100%)**
└多輪看圖第 2 輪快取命中 TTFT	2.21 s (cached=0)	0.76 s (10K)	0.71 s (10K)	0.73 s (10K)	0.73 s (10K)	**0.71 s (快 3.1 倍)**
Part B：單流 `temp=0.0` Code 解碼	90.90 tok/s	82.69 tok/s	77.54 tok/s	92.99 tok/s	92.93 tok/s	**93.28 tok/s (+20.3%)**
└`temp=0.0` Code MTP 草稿接受率	74.5%	72.3%	80.6%	80.3%	80.3%	**80.3% (TTFT 0.160s)**
單流 `temp=0.0` 結構化 JSON 解碼	—	83.08 tok/s	104.24 tok/s	106.66 tok/s	106.53 tok/s	**107.08 tok/s (MTP 87.4%)**
單流 `temp=0.3` 日常 Code 解碼	75.90 tok/s	78.13 tok/s	74.30 tok/s	79.50 tok/s	79.00 tok/s	**79.79 tok/s (+7.4%)**
└`temp=0.3` Code MTP 草稿接受率	67.6%	69.5%	73.5%	75.3%	74.1%	**74.1% (TTFT 0.160s)**
單流 `temp=0.3` 中文長文 / JSON 解碼	65.7 / 112.1	60.4 / 106.7	59.1 / 88.1	61.5 / 105.4	61.4 / 105.7	**60.7 / 105.5 tok/s**
冷預填吞吐：8K 級距 (~15.5K toks)	2,269 tok/s	1,146.9 tok/s	1,892.5 tok/s	2,225.4 tok/s	2,238.9 tok/s	**2,260.0 tok/s (+19.4%)**
└8K 冷預填首字延遲 (Client TTFT)	—	12.47 s	8.15 s	7.44 s	6.89 s	**6.95 s (比初版快 44%)**
冷預填吞吐：32K 級距 (~63K toks)	2,295 tok/s	1,997.1 tok/s	1,955.3 tok/s	2,054.9 tok/s	2,033.5 tok/s	**2,037.4 tok/s (TTFT 31.2s)**
32K 冷預填期間短請求插隊 TTFT	26.350 秒	4.772 秒	1.630 秒	1.137 秒	1.132 秒	**1.133 秒 (再快 30.5%)**
└插隊短請求總完成耗時 (Wall Time)	27.10 秒	4.85 秒	1.71 秒	1.22 秒	1.21 秒	**1.21 秒 (比原始快 22 倍)**

四、Part C：多路併發吞吐擴展 (C1–C6) 與 Port 8889 突發防線對比

併發與壓力測試指標	1. 初始 2B-2 `live-1027` （4槽）	2. 架構更動前 P4h （4槽基線）	3. Strata+8K P4n （4槽協同）	4. 擴展 6槽8佇列 P5 （6槽擴展）	5. 最終生產架構 P6 （6槽+ColdKV）	架構升級增幅 (P6 vs P4h)
C1 單路聚合吞吐 (tok/s)	75.65 tok/s	75.52 tok/s	76.83 tok/s	76.52 tok/s	76.52 tok/s	**+1.3%**
C2 雙路併發聚合吞吐 (tok/s)	74.80 tok/s	87.74 tok/s	88.95 tok/s	87.41 tok/s	87.85 tok/s	**+0.1% (較初版 +17.4%)**
C4 四路併發聚合吞吐 (tok/s)	112.30 tok/s	112.66 tok/s	**115.80 tok/s**	112.73 tok/s	112.21 tok/s	持平 (4路未滿 6槽)
C6 六路滿載聚合吞吐 (tok/s)	不支援 (上限 4槽)	不支援 (上限 4槽)	不支援 (上限 4槽)	**170.07 tok/s**	**169.95 tok/s**	**+51.0% (突破 4槽上限)**
瞬間突發容量測試 (200 OK 承載數)	8 路 (C10 突發)	8 路 (C10 突發)	8 路 (C10 突發)	**14 路 (C16 突發)**	**14 路 (C16 突發)**	**在線承載容量 +75.0%**
超額突發 HTTP 429 秒退延遲	1.2 ms (第 9-10 路)	1.8 ms (第 9-10 路)	1.9 ms (第 9-10 路)	**1.3 ms (第 15-16 路)**	**1.2 ms (第 15-16 路)**	**1.2 ms 極速觸發雲端備援**
C8 重度卡頓測試 (8 路長任務)	5路 200 / 3路 429	5路 200 / 3路 429	5路 200 / 3路 429	**8 路全數 200 OK**	**8 路全數 200 OK**	**8 路完全吸收免退場**

五、Part D：Strata 多代理併發與進階快取評測 (D1–D4) 全量對比

Part D 專為檢驗真實多 Agent 協同工作流（如多個子代理同時掃描 30K tokens 專案代碼庫、錯開進場、6 輪工具呼叫循環、背景掃描與前台互動混跑）而設計。以下為**更動架構前（P4h：無 Single-Flight、4096 快取門檻）**與**新架構（P4n 4槽協同 & P6 6槽最終架構）**的逐項實測對比：

Part D 多代理測試場景與細項指標	更動架構前基線 (P4h: 無協同 / 4K門檻)	Strata + 8K + 3GB (P4n: 4槽 Single-Flight)	最終生產架構 (P6: 6槽 + Single-Flight)	對比改善幅度 (P6 vs P4h 基線)
D1：4 子代理同時突發掃描 30K 專案代碼庫 (Burst Delay-Hit 場景)				
└ Leader 首路預填回應延遲 (Leader TTFT)	2.961 秒	**0.893 秒**	**0.959 秒**	**加速 3.1 倍 (-67.6%)**
└ Follower 兄弟請求平均 TTFT	2.309 秒	2.678 秒	2.858 秒	受 Single-Flight 秩序保護
└ 4 路 Worker 快取命中 Tokens (cached_tokens)	26,624 × 4	**26,624 × 4 (100% 命中)**	**26,624 × 4 (100% 命中)**	**零重複冷預填**
└ D1 批次總完成時間 (Wall) / 聚合吞吐	12.04 s / 85.04 tok/s	12.18 s / 84.04 tok/s	**11.83 s / 86.54 tok/s**	**吞吐 +1.8% • 總耗時 -1.7%**
D2：4 子代理錯開時序流式進場 (Staggered In-Flight Pipeline Overlap)				
└ Worker 0 首字延遲 (TTFT) / 快取命中	14.475 秒 (cached=0)	**0.952 秒 (26,624)**	**0.950 秒 (26,624)**	**加速 15.2 倍 (-93.4%)**
└ Worker 1 首字延遲 (TTFT) / 快取命中	12.509 秒 (26,624)	**0.944 秒 (26,624)**	**0.964 秒 (26,624)**	**加速 13.0 倍 (-92.3%)**
└ Worker 2 首字延遲 (TTFT) / 快取命中	7.781 秒 (26,624)	**0.938 秒 (26,624)**	**0.960 秒 (26,624)**	**加速 8.1 倍 (-87.7%)**
└ Worker 3 首字延遲 (TTFT) / 快取命中	10.507 秒 (26,624)	**0.933 秒 (26,624)**	**0.958 秒 (26,624)**	**加速 11.0 倍 (-90.9%)**
└ D2 錯開進場批次總完成耗時 (Wall Total)	**21.78 秒**	**12.76 秒**	**12.82 秒**	**批次加速 41.1% (省 8.96s)**
D3：6 輪連續自主代理工具鏈對話 (2048 粒度快取起跑驗證)				
└ Turn 1 (220 toks) / Turn 2 (584 toks) TTFT	0.359 s / 0.579 s	0.344 s / 0.542 s	**0.330 s / 0.535 s**	**TTFT 改善 -8.0%**
└ Turn 3 (1,013 toks) / Turn 4 (1,503 toks) TTFT	0.767 s / 0.940 s	0.731 s / 0.925 s	**0.720 s / 0.920 s**	**全程穩定低於 1 秒**
└ Turn 5 (2,055 toks) TTFT / 單輪總耗時	1.231 s / 2.47 s	1.198 s / 2.42 s	**1.191 s / 2.42 s**	**此輪建立 2,048 快取塊**
└ Turn 6 (2,669 toks) 快取命中與 TTFT	**1.594 s (cached=0, 0%)**	**0.551 s (cached=2,048)**	**0.529 s (cached=2,048, 76.7%)**	**快 3.0 倍 (-66.8% 首字延遲)**
└ Turn 6 單輪完成總耗時 (Wall Time)	3.137 秒	**2.081 秒**	**2.061 秒**	**單輪提速 -34.3%**
D4：混合負載前台互動保證 (2 路 P2 背景 30K 掃描 + 2 路 P0 前台互動)				
└ 前台互動 User 1 (P0) TTFT / 總完成耗時	0.661 s / 16.75 s	**0.425 s / 2.64 s**	**0.478 s / 2.72 s**	**前台總耗時快 6.2 倍**
└ 前台互動 User 2 (P0) TTFT / 總完成耗時	2.005 s / 17.88 s	**0.165 s / 2.21 s**	**0.138 s / 2.22 s**	**TTFT 快 14.5 倍 • 耗時快 8 倍**
└ 背景批次 Worker 1 (P2) TTFT / 總耗時 (快取)	15.912 s / 32.67 s (0)	**0.909 s / 5.60 s (26,624)**	**0.931 s / 5.66 s (26,624)**	**TTFT 快 17.1 倍**
└ 背景批次 Worker 2 (P2) TTFT / 總耗時 (快取)	31.102 s / 33.68 s (0)	**1.605 s / 5.59 s (26,624)**	**1.647 s / 5.66 s (26,624)**	**TTFT 快 18.9 倍**
└ D4 混合負載全批次完成總耗時 (Wall Total)	**33.90 秒**	**5.80 秒**	**5.87 秒**	**整體加速 5.8 倍 (快 477%)**

六、高壓長跑實戰對比：調優前 30 分鐘壓測 vs 最終架構 5 小時馬拉松

為徹底驗證新架構在長時間極限負載下的穩定度，我們以完全相同的 **8 併發持續隨機轟炸模型**（6 槽滿載 + 2 佇列待命；混合 Short <2K、Medium 2K–8K、Long 10K–29.6K 上下文；60% 高命中共享前綴 + 40% 動態隨機獨立前綴；33% Thinking 深度思考 + 66% 標準代碼生成）進行對照：

高壓併發長跑統計維度	調優前：6 槽初版 30m 壓測 (stress_30min)	5 小時高壓馬拉松 (3,519筆) (stress_5hour)	Opus 5.5 + Astra 審查修復後 (P7 E1+E2 實測對照)
測試連續時長 / 併發度	30 分鐘 / 8 併發	300 分鐘 (5 小時) / 8 併發	8 併發同種子壓測 (E1+E2 硬化版)
累計發起總請求數	400 筆	3,519 筆	40 筆全分布對照 + 全套 Part A–D
HTTP 200 OK 成功交付數 (成功率)	260 筆 (65.00%)	3,354 筆 (95.31%)	87.5% ~ 95.31% (較初版 +30.3%)
HTTP 429 階梯秒退保護數 (比例)	134 筆 (33.50%)	156 筆 (4.43%)	無謂退場率大降 • 0 前綴鎖洩漏
HTTP 500 客戶端 120s 超時異常	6 筆 (1.50%)	9 筆 (0.26%)	0 筆 (0.00% • 徹底清零)
引擎累計處理 Prompt Tokens (/metrics)	~3,012,246 tokens	56,024,106 tokens (5,602 萬)	平均每秒處理 3,112 prompt tok/s
達標長中請求 (≥2560 toks) RAM 保持率	82.0% (Token 加權)	96.10% (1,282/1,334) • 83.5% 全局	100.0% RAM 熱池命中 (0 NVMe 落盤)
累計生成 Output Tokens (/metrics)	41,244 tokens	1,464,897 tokens (146.5 萬)	含完整深度思考鏈與代碼輸出
全週期 MTP 投機草稿接受率	~78.5%	79.11% (874,764 / 1,105,694)	80.3% (單流) / 79.11% (長跑)
整體首字延遲 (TTFT)：中位數 / 平均	7.783 秒 / 15.977 秒	5.948 秒 / 10.696 秒	3.910 秒 (-49.8%) / 7.215 秒 (-54.8%)
整體首字延遲 (TTFT)：P90 / 最快命中	39.328 秒 / 0.0137 秒	25.563 秒 / 0.0210 秒	19.010 秒 (P90 壓縮 -51.7%)
單任務總耗時 (Wall)：中位數 / 平均	44.65 秒 / 48.46 秒	38.82 秒 / 41.91 秒	45.05 秒 / 44.79 秒 (6路384真滿載)
優先權分層：Priority 0 (前台互動) TTFT	中位數 4.752 秒	中位數 4.298 秒 (平均 5.61s)	中位數 1.963 秒 (快 2.4 倍, 平均 4.98s)
優先權分層：Priority 1 (一般任務) TTFT	中位數 6.516 秒	中位數 4.989 秒 (平均 7.12s)	中位數 5.602 秒 (Cache-Aware 提拔)
優先權分層：Priority 2 (背景批次) TTFT	中位數 23.476 秒 (誤卡3槽)	中位數 22.428 秒 (誤卡3槽)	0.007 秒直通 (修復 bg_max=5 + 10s Aging)

七、雙節點記憶體成分帳本 (Memory Audit Ledger) 與硬體穩定性對比

雙節點硬體與記憶體審計項目	更動架構前基線 (P4h： 4槽 + 2GB快取)	新架構標準評測後 (P6： 6槽 + 3GB快取)	5 小時馬拉松完賽後 (3,519 筆高壓長跑後)	安全邊界與架構狀態判定
引擎活躍工作集 (Active Working Set)	105.12 GiB	103.65 GiB	106.55 GiB	含 99.2G 權重 + 6.44G KV Pool + Graph
KV Pool 總容量 / 主機 Prompt Cache	1.05M toks / 2.0 GiB	1.05M toks / 3.0 GiB	1.05M toks / 3.0 GiB	3.0 GiB 快照池徹底消除頻繁淘汰
Node 1 (spark-9e5c) 實體可用記憶體	5,599 MiB (5.47 GiB)	7,061 MiB (6.90 GiB)	3,952 MiB (3.86 GiB)	穩守 High-Watermark (3.5 GiB) 之上
Node 2 (spark-7579) 實體可用記憶體	8,083 MiB (7.89 GiB)	9,602 MiB (9.38 GiB)	5,921 MiB (5.78 GiB)	Node 2 Swap 使用量維持 0 MiB
LMCache 分層 NVMe 冷盤快取狀態	未啟用	7 會話 (0.46 MB)	124 會話 (5.19 MB / 200GB)	高於 3.5G 水位時 100% 留存 UMA 熱池
GPU 動態溫控與叢集健康度	71°C / 61°C • 0 錯誤	72°C / 61°C • 0 錯誤	待機 42°C (10W) • 0 錯誤	0 OOM • 0 BadSlot • 0 RDMA 斷線

報告檔案路徑：/home/joseyarashio/dgx-spark-tp2-recipes/reports/DGX_Spark_TP2_Comprehensive_Benchmark_Report_20261107.pdf
可重現驗證與原始數據：/home/joseyarashio/dgx-spark-tp2-recipes/benchmarks/results/ • GitHub: https://github.com/joseyarashio/dgx-spark-tp2-recipes (Tag: v2b2-p6-5hour-marathon-verified, Commit: 497e634)